

# 星火智学伦理与安全合规声明

DRAFT · 待团队负责人、指导教师和数据/安全责任人真实签署

|                    |                                                                  |
|--------------------|------------------------------------------------------------------|
| Git commit         | 313d2fab804d2526cf4625cf603b4ff5845c63ee                         |
| 法源manifest SHA-256 | 78360315a0e3b29f1c34bceeb3ccfde7ee75aa8b16c56efe3a8f20701f0e76d7 |
| 关键法条时效复核           | 5/5 · 2026-08-29T23:53:58+08:00                                  |
| 专家审核               | 材料已就绪，真实专家未审核或签字                                                 |
| 目标用户               | 预分配U01/U02，真实参与者0人                                               |
| 演示视频               | 121.6秒 · 1920x1080 · AI配音DRAFT                                   |

## 一、项目用途与责任边界

星火智学面向本科刑法课堂，提供形成性认知诊断、可信法源检索、个性化学习任务、多智能体案件实训与教师复核。系统只用于教学支持与比赛演示，不替代任课教师、司法机关或执业律师，不自动发布正式成绩或法律意见。

本声明是团队对数据、AI输出、教学边界与安全措施的自我约束。团队签署不等于学校授权、机构伦理委员会审批、课堂试点批准、法学专家背书或法律服务资质。

## 二、数据来源与最小化

- 法律文本来自受治理的本地法源快照，保存来源、版本和SHA-256；正式提交前、每学期开课前和真实法律使用前重新复核。
- 本次只对5条演示关键法条完成2026年时效与逐字一致性审计，不宣称全量法库已逐条复核。
- ORCDF实验使用MOOCCubeX民法/宪法匿名行为数据，只用于迁移研究和shadow展示，不冒充本科刑法课堂数据。
- 冻结Demo使用虚构邮箱、本地SQLite和确定性脚本输入；不把浏览器smoke、29次固定回答或演示事件冒充真实学生。
- 目标用户试用只收集完成比赛验证所需的最小角色背景、任务、时长、量表与反馈；公开材料只用U01/U02编号。

### 三、AI生成内容与教师责任

- 页面、PPT和视频显著标注AI生成或AI辅助内容；视频AI配音DRAFT尚待团队完整审片。
- 大模型只提供追问、解释、对抗与形成性反馈草稿；主观题只有教师批准后才形成长期画像证据。
- 错条号、伪造引文、越界Evidence、坏JSON和低置信度输出必须拒绝、弃权、回退或进入教师复核。
- 当前基线为OpenCode/DeepSeek兼容路由；微调端点not\_connected，不得表述为已完成LoRA/SFT。
- 三题自动门禁3/3只证明结构、要点、来源范围和逐字quote门禁；不等于专家准确率。

### 四、认知诊断与推荐边界

- insufficient\_evidence表示证据不足；provisional表示临时证据状态，均不是校准掌握概率。
- 困惑是学生自报信号，不直接作为答错、扣分或正式成绩证据。
- ORCDF mastery是未校准潜变量；MOOCCubeX训练只可作为通用初始化研究，不直接迁移旧学生、题目或知识参数。
- 七步个性化路径是基于当前证据的可解释候选排序，不宣称因果最优或已验证学习增益。

### 五、案件智能体与法律结论边界

- Agent只能围绕受治理案件事实与获准工具活动，不得虚构证据、法源或专家意见。
- case3不起诉是固定脚本输入下的模型/状态机演示分支，不是独立专家确认的法律结论或真实案件结果保证。
- 任何面向课堂发布的标准答案、指导案例要点和形成性评价仍需任课教师审核。

## 六、隐私、访问与保留

- API Key、Token、完整私有端点和私有绝对路径不得进入前端响应、日志、截图、PPT、视频或公开附件。
- 学生历史、困惑和主观稿按登录身份隔离；教师只查看自有班级匿名形成性数据。
- LearningEvent不可变且幂等；同一主观稿最多一次教师决定和一次画像事件。
- 签名同意书与去标识试用记录分开保存；签名原件只允许负责人和指定证据管理员访问，不提交Git。
- 目标用户原始记录在比赛结果公布后90天删除，最长不超过180天；撤回后7天内删除尚未公开的原始记录。
- 演示录屏必须隐藏邮箱、内部用户ID、令牌、密钥、私有路径和未经授权的困惑原文。

## 七、安全措施与事件处置

- 本地演示使用SQLite + adaptive + Vite，不把Docker或外部在线服务作为比赛演示的必需链路。
- 法源检索优先使用本地受治理语料；外部模型或检索失败时必须有拒答、回退或离线快照。
- 发现密钥、真实身份、未授权录屏或错误法律结论泄漏时，立即停止录制/发布，撤下材料、轮换密钥并记录处置。
- 任何数据或内容版本变化都应更新manifest、SHA、模型/Prompt版本和审计日期，禁止静默覆盖旧证据。

## 八、目标用户试用要求

- 参与完全自愿，可随时停止且不影响课程成绩或其他权益；试用不是正式考试或学习效果实验。
- U01/U02使用独立虚构账号和统一T1-T4；每项最多一次不含答案的中性提示。
- 2人样本只报告有效n、中位数和范围，不做显著性检验，不外推诊断效度或学习效果。

## 九、主要风险与控制

| 确认  | 门禁             | 当前状态/复核记录                          |
|-----|----------------|------------------------------------|
| [ ] | 法条过期或引用错误      | 版本化法源、逐字quote门禁、5条关键法条审计、教师复核、失败弃权 |
| [ ] | 模型偏见或不稳定       | 独立金标准、A/B专家审核、低置信回退、保留模型与Prompt版本  |
| [ ] | 形成性评价被误当正式成绩   | UI/PPT/报告持续标识；不接正式成绩发布             |
| [ ] | 学生画像误判         | 证据不足优先、事件可追溯、教师解释、学生修订             |
| [ ] | 用户试用隐私泄漏       | 知情同意、最少字段、编号、私密/公开分包、限定保留期         |
| [ ] | 演示数据被冒充真实课堂    | 虚构账号和固定脚本显著披露；真实用户与专家状态独立记录        |
| [ ] | Agent适法结论被过度宣传 | 明确演示分支；专家PENDING；答辩与材料保留限定语        |

## 十、签署与发布条件

公开正文可用于团队内部复核和比赛附件草案。只有三名责任角色完成私密签署页、签署前核对清单通过且材料SHA固定后，团队才能把本声明标为“已签署”。如比赛要求公开签署信息，必须另行确认签署人的公开授权。

在真实签署前，本声明保持DRAFT；在专家、目标用户或视频审批尚未完成时，相应PENDING状态继续保留，不因签署伦理声明而自动变为已验证。

|        |                      |
|--------|----------------------|
| 专家审核状态 | PENDING · 审核包已就绪，未签字 |
| 目标用户状态 | PENDING · 真实参与者0人    |
| 视频状态   | DRAFT · 待团队完整审片      |
| 微调状态   | NOT_CONNECTED        |
| 声明签署状态 | PENDING · 私密签署页为空白   |