

星火智学效果验证报告

DRAFT · L1软件证据已形成，L2专家、L3真实用户、L4学习效果均未完成

报告状态	DRAFT · 待内容、数据、教学三角色批准
证据范围	软件机制、模型接口、真实API探针与候选消融
最终提交就绪	否

一、结论分层

层级	要回答的问题	当前证据	当前结论
L1 软件机制	功能是否按契约运行	自动化、三案例浏览器彩排、真实配置E2E、媒体QA	已验证到本报告列明范围
L2 法学内容	三题结论和边界是否可靠	自动检查3/3；A/B专家包	自动检查通过，真实专家未审核
L3 用户可用性	目标用户能否理解并完成任务	U01/U02标准化空白材料	真实参与者0人，无用户结论
L4 学习效果	是否提高保持、迁移或成绩	前后测、延迟测、对照实验	尚未开展，不作效果声称

二、报告允许表达的总论

当前证据支持“比赛演示版的软件闭环、来源治理、媒体质量和教师复核机制可复现”，不支持“已证明刑法认知诊断有效、个性化路径提高成绩、微调模型优于基线、专家已认可或用户已满意”。

三、L1软件机制证据

机制	当前结果	证据边界
Evidence-KT	10个刑法知识点；证据不足和临时画像门槛；事件与困惑可追溯	状态不是校准掌握概率
ORCDF shadow	同47题AUC V0/V1/V2=0.7272/0.7489/0.7528	数据来自MOOCCubeX民法/宪法；不可用主范围比较Q矩阵优劣
七步路径	薄弱点、先修、选择、主观、案件、角色互换、复习	候选排序，不宣称因果最优
Model Adapter	火山引擎Ark基线；DeepSeek官方瞬态回退；任务统一路由	队友微调模型待交付，不称LoRA/SFT完成
Hybrid RAG	57,051条三库索引；候选Recall@5=0.86；无答案误返回=0	120条qrels教师复核0；候选结果不等于正式准确率
NLI模板初筛	180/180完成；三类各60；模型候选一致率1.00	教师Gold为0；模型一致不等于NLI准确率
知识图/实时语音	10节点、10条先修边、6步论证模板；讯飞实时IAT partial/final、Evidence回复与TTS多轮通过	ASR需复核、媒体不进入画像；OCR/数字人未连接
可信RAG	三题自动检查3/3；错误引用2/2拒绝	自动检查不等于专家准确率
教师HITL	退回-原文修订-批准；同稿单决定、单事件	合成账号浏览器闭环，不是用户试用
case3 Agent	461.547秒、29次固定回答、3/3 Agent退场、0错误	不是29名用户；不起诉分支非专家结论

四、L1量化与交付QA

证据对象	结果	能证明	不能证明
冻结演示库	源24/24、恢复24/24	备份恢复语义一致	真实课堂稳定性
关键法条	5/5	5条来源、版本、文本一致	全量法库或具体适法正确
三案例彩排	3/3、107.25秒、浏览器错误0	同一本地栈三条UI路线可重复	真实用户认可或学习效果
网页PPT	13页、浏览器错误0、溢出0	主要视口可用	目标用户可用性
PPTX	13页、1,640,817字节；PowerPoint回渲染13页；最大像素差1.824442	PPTX结构、视觉源和实际PowerPoint渲染一致	内容专家认可
演示视频	162.2秒、12/12、1.05677x、静音0	≤180秒、内容覆盖、实时语音与媒体检查	团队批准或用户认可

五、ORCDF受控解释

- V0：1,256题、126,073作答、180个原始exercise_id；同47题AUC 0.7272。
- V1：590可训练题、124,121作答、74个LLM候选概念、741条Q边；同47题AUC 0.7489。
- V2：47题、7,356作答、97个教师知识点、105条Q边；同47题AUC 0.7528。
- V1-V0同47题差0.0299，seed42学生聚类bootstrap 95%CI [0.0037,0.0537]；这不等于刑法课堂效果。
- V2 mastery集中在0.5附近且未校准，只能称相对状态；新刑法课堂只做通用层初始化与scratch对照。

六、L2法学内容验证

题目	自动检查	专家状态	允许结论
罪刑法定与从旧兼从轻	通过	待复核	仅称结构/要点/引用检查通过
正当防卫与特殊防卫	通过	待复核	case3适法仍需专家判断
抢劫罪基本构成	通过	待复核	价值低不当然排除仍需专家复核

三题使用的目标法条已纳入5/5时效审计，但法条文本现行只消除文本过期/篡改风险，不替代事实涵摄、争议判断和独立专家签署。

专家审核包	8份PDF、21页；A包盲审隔离和秘密扫描通过
真实专家完成	false

七、L3目标用户验证

预分配编号	U01、U02
标准化材料	6份PDF、11页；私密同意与公开记录分离
真实参与者	0
真实记录完成	false

只有两人真实完成后，才报告各任务有效n、完成状态、量表中介数/范围和经授权原话；2人样本不做显著性检验。

八、L4学习效果

尚未开展前后测、延迟测、对照实验或功效分析。本报告不声称成绩提升、保持改善、迁移增强或路径因果效果。

九、材料批准与剩余缺口

视频技术状态	DRAFT待批准；团队批准0/3
伦理签署	0/3
专家审核	0个完成签署结论
目标用户	0/2
本效果报告批准	0/3

十、不支持的结论

- 刑法掌握率达到X%。
- 个性化路径使成绩提升X%或因果最优。
- V2教师Q矩阵显著优于V1，或主范围AUC可以直接比较。
- 微调模型优于基线，或已经完成LoRA/SFT。
- 已完成伦理审批、课堂试点、专家准确率、用户满意度或50人实验。

十一、报告状态

本PDF是证据索引化DRAFT。只有内容、数据、教学三名复核人一致批准，且最终引用的专家/用户/视频状态与证据文件一致后，才能升级为最终报告。