

# 星火智学效果验证报告

DRAFT · L1软件证据已形成，L2专家、L3真实用户、L4学习效果均未完成

|             |                                                                  |
|-------------|------------------------------------------------------------------|
| Git commit  | 54326efa5431520df4f49e54e6f1da4ded7a07cd                         |
| 证据索引SHA-256 | 48ff649b8366fa16e4a43d6564fec32d677cb4f97b2208a5bbc37ff4cbc9d5ba |
| 报告状态        | DRAFT · 待内容、数据、教学三角色批准                                           |
| 最终提交就绪      | 否                                                                |

## 一、结论分层

| 层级       | 要回答的问题        | 当前证据                 | 当前结论           |
|----------|---------------|----------------------|----------------|
| L1 软件机制  | 功能是否按契约运行     | 自动化、浏览器、真实配置E2E、媒体QA | 已验证到本报告列明范围    |
| L2 法学内容  | 三题结论和边界是否可靠   | 自动门禁3/3；A/B专家包       | 自动门禁通过，真实专家未审核 |
| L3 用户可用性 | 目标用户能否理解并完成任务 | U01/U02标准化空白材料       | 真实参与者0人，无用户结论  |
| L4 学习效果  | 是否提高保持、迁移或成绩  | 前后测、延迟测、对照实验         | 尚未开展，不作效果声称    |

## 二、报告允许表达的总论

当前证据支持“比赛演示版的软件闭环、来源治理、媒体质量和人工门禁机制可复现”，不支持“已证明刑法认知诊断有效、个性化路径提高成绩、微调模型优于基线、专家已认可或用户已满意”。

### 三、L1软件机制证据

| 机制            | 当前结果                                  | 证据边界                             |
|---------------|---------------------------------------|----------------------------------|
| Evidence-KT   | 10个刑法知识点；证据不足和provisional门槛；事件与困惑可追溯  | 状态不是校准掌握概率                       |
| ORCDF shadow  | 同47题AUC V0/V1/V2=0.7272/0.7489/0.7528 | 数据来自MOOCCubeX民法/宪法；不可用主范围比较Q矩阵优劣 |
| 七步路径          | 薄弱点、先修、选择、主观、案件、角色互换、复习               | 候选排序，不宣称因果最优                     |
| Model Adapter | OpenCode/DeepSeek基线；四任务统一路由           | 微调not_connected，不称LoRA/SFT完成     |
| 可信RAG         | 三题自动门禁3/3；错误引用2/2拒绝                   | 自动门禁不等于专家准确率                     |
| 教师HITL        | 退回-原文修订-批准；同稿单决定、单事件                  | 合成账号浏览器闭环，不是用户试用                 |
| case3 Agent   | 461.547秒、29次固定回答、3/3 Agent退场、0错误      | 不是29名用户；不起诉分支非专家结论               |

## 四、L1量化与交付QA

| 证据对象       | 结果                     | 能证明             | 不能证明        |
|------------|------------------------|-----------------|-------------|
| 冻结演示库      | 源24/24、恢复24/24         | 备份恢复语义一致        | 真实课堂稳定性     |
| 关键法条       | 5/5                    | 5条来源、版本、文本一致    | 全量法库或具体适法正确 |
| 网页PPT      | 12页、浏览器错误0、溢出0         | 主要视口可用          | 目标用户可用性     |
| PowerPoint | 12页、最大回渲染误差0.0953      | Office渲染稳定      | 内容专家认可      |
| 演示视频       | 121.6秒、7/7、1.0371×、静音0 | ≤180秒、内容覆盖、媒体门禁 | 团队批准或用户认可   |

## 五、ORCDF受控解释

- V0: 1,256题、126,073作答、180个原始exercise\_id；同47题AUC 0.7272。
- V1: 590可训练题、124,121作答、74个llm\_provisional概念、741条Q边；同47题AUC 0.7489。
- V2: 47题、7,356作答、97个教师知识点、105条Q边；同47题AUC 0.7528。
- V1-V0同47题差0.0299，seed42学生聚类bootstrap 95%CI [0.0037,0.0537]；这不等于刑法课堂效果。
- V2 mastery集中在0.5附近且未校准，只能称相对状态；新刑法课堂只做通用层初始化与scratch对照。

## 六、L2法学内容验证

| 题目         | 自动门禁 | 专家状态    | 允许结论           |
|------------|------|---------|----------------|
| 罪刑法定与从旧兼从轻 | 通过   | PENDING | 仅称结构/要点/引用门禁通过 |
| 正当防卫与特殊防卫  | 通过   | PENDING | case3适法仍需专家判断  |
| 抢劫罪基本构成    | 通过   | PENDING | 价值低不当排除仍需专家复核  |

三题使用的目标法条已纳入5/5时效审计，但法条文本现行只消除文本过期/篡改风险，不替代事实涵摄、争议判断和独立专家签署。

|        |                         |
|--------|-------------------------|
| 专家审核包  | 8份PDF、21页；A包盲审隔离和秘密扫描通过 |
| 真实专家完成 | false                   |

## 七、L3目标用户验证

|        |                       |
|--------|-----------------------|
| 预分配编号  | U01、U02               |
| 标准化材料  | 6份PDF、11页；私密同意与公开记录分离 |
| 真实参与者  | 0                     |
| 真实记录完成 | false                 |

只有两人真实完成后，才报告各任务有效n、完成状态、量表中介数/范围和经授权原话；2人样本不做显著性检验。

## 八、L4学习效果

尚未开展前后测、延迟测、对照实验或功效分析。本报告不声称成绩提升、保持改善、迁移增强或路径因果效果。

## 九、材料批准与剩余缺口

|         |                      |
|---------|----------------------|
| 视频技术状态  | draft_ready; 团队批准0/3 |
| 伦理签署    | 0/3                  |
| 专家审核    | 0个完成签署结论             |
| 目标用户    | 0/2                  |
| 本效果报告批准 | 0/3                  |

## 十、不支持的结论

- 刑法掌握率达到X%。
- 个性化路径使成绩提升X%或因果最优。
- V2教师Q矩阵显著优于V1，或主范围AUC可以直接比较。
- 微调模型优于基线，或已经完成LoRA/SFT。
- 已完成伦理审批、课堂试点、专家准确率、用户满意度或50人实验。

## 十一、报告状态

本PDF是证据索引化DRAFT。只有内容、数据、教学三名复核人一致批准，且最终引用的专家/用户/视频状态与证据文件一致后，才能升级为最终报告。